

INBreast sa Mask2Former modelom


1. Opis problema

Karcinom dojke i dalje ostaje jedna od najrasprostranjenijih i najopasnijih bolesti koja pogađa žene širom sveta. Rana detekcija bolesti ima ključnu ulogu u poboljšanju ishoda kod pacijentkinja, što čini razvoj preciznih i efikasnih dijagnostičkih alata imperativom. U poslednjih nekoliko godina, napredak u dubokom učenju i tehnikama kompjuterske vizije otvorio je nove puteve za unapređenje analize medicinskih slika, posebno u oblasti detekcije karcinoma dojke.

U ovom istraživanju je predstavljen pristup koji koristi modele dubokog učenja bazirane na transformerima za segmentaciju slika dojke radi pomoći u detekciji kancerogenih regiona. Korištena je biblioteka *mmsegmentation* koja implementira mnoge modele dubokog učenja, a specifično, model koji je korišten u ovom izveštaju naziva se *Mask2Former*. Predloženi model koristi snagu mehanizama transformera kako bi uhvatio kompleksne prostorne odnose i karakteristike unutar mamografskih slika.

Korišteni skup podataka se sastoji iz *x-ray* mamografskih slika ženskih dojki i odgovarajućih maski za svaku sliku koja ukazuje na regione slike koji sadrži ciljne bolesti za prepoznavanje. Primjer jednog para slika-maski je data na Slika 1.

Ovaj izveštaj opisuje metodologiju korištenu u razvoju modela segmentacije baziranog na transformerima, razmatra eksperimentalna otkrića i procenjuje performanse modela.



Slika 1. Primjer jednog para slika-maski i korištenog skupa podataka.

2. Značaj problema

Karcinom dojke predstavlja značajan javnozdravstveni izazov širom sveta. Prema Svetskoj zdravstvenoj organizaciji, karcinom dojke bio je odgovoran za otprilike 519.000 smrtnih slučajeva u 2004. godini, što čini 16% od ukupnog broja slučajeva karcinoma među ženama. U 2008. godini, bio je najčešći oblik karcinoma i uzrok smrti od karcinoma kod žena širom sveta. U Portugalu, 1500 žena umire svake godine od karcinoma dojke, dok je u Evropskoj uniji odgovoran za jednu od šest smrtnih slučajeva od karcinoma kod žena. Zbog toga, rano otkrivanje i dijagnoza karcinoma dojke su od suštinskog značaja za smanjenje povezane smrtnosti.

Razvoj efikasnih metoda za rano otkrivanje karcinoma dojke predstavlja ključnu oblast istraživanja u medicini, imajući u vidu visoku stopu incidencije ove bolesti i njen značajan uticaj na zdravlje žena širom sveta. Navedeni problem ima izuzetan značaj iz nekoliko ključnih razloga.

Prvo, rana detekcija karcinoma dojke direktno utiče na ishod lečenja i preživljavanje pacijentkinja. Studije su pokazale da se rano otkriveni tumori dojke uspešno mogu tretirati, često sa manjim invazivnim metodama i boljim prognozama za pacijentkinje. Stoga, razvoj preciznih dijagnostičkih alata koji omogućavaju ranu identifikaciju potencijalno kancerogenih regiona na mamografskim slikama ima direktan uticaj na smanjenje smrtnosti od ove bolesti.

Drugo, implementacija efikasnih metoda za detekciju karcinoma dojke može znatno smanjiti troškove zdravstvenog sistema i opterećenje na zdravstvene resurse. Kasna dijagnoza karcinoma dojke često zahteva agresivnije oblike lečenja, što dovodi do povećanih troškova za zdravstvene ustanove i pacijentkinje. Razvoj automatskih alata za detekciju tumora dojke može olakšati proces dijagnostike i smanjiti vreme potrebno za analizu medicinskih slika, što dovodi do efikasnijeg upravljanja resursima i smanjenja troškova lečenja.

Treće, kvalitetna dijagnostika karcinoma dojke može poboljšati kvalitet života pacijentkinja i pružiti im veću sigurnost u postupke lečenja. Rana identifikacija potencijalno kancerogenih lezija omogućava pacijentkinjama da pravovremeno započnu terapiju i da se suoče sa bolešću na adekvatan način. Ovo ne samo da doprinosi fizičkom, već i emocionalnom blagostanju pacijentkinja, pružajući im osećaj kontrole nad svojim zdravstvenim stanjem.

U svetlu navedenih razloga, razvoj i implementacija naprednih algoritama za detekciju karcinoma dojke predstavljaju ključne korake ka poboljšanju zdravstvene zaštite žena

široj svijetu. Korišćenje transformatorskih modela za segmentaciju mamografskih slika predstavlja inovativan pristup koji obećava poboljšanje tačnosti i brzine dijagnostičkog procesa, pružajući nadu za bolje ishode i veće preživljavanje pacijentkinja sa karcinomom dojke.

3. Upoređivanje različitih pristupa rešenju problema

Razvoj efikasnih alata za detekciju i dijagnozu karcinoma dojke podrazumeva korišćenje različitih pristupa i tehnika. U ovoj sekciji, upoređeno je nekoliko glavnih pristupa rešenju problema, ističući njihove prednosti i mane.

1. Klasične metode analize medicinskih slika:

Prednosti: Klasične metode analize medicinskih slika, poput ručno definisanih pravila i filtera, bile su široko korišćene pre razvoja dubokih neuronskih mreža. Ove metode su često transparentne i mogu biti lakše interpretirane.

Mane: Klasične metode često zahtevaju ručno definisane funkcije i heuristike, što može biti ograničavajuće u slučaju kompleksnih problema kao što je detekcija karcinoma dojke. Osim toga, ove metode mogu biti manje efikasne u hvatanju suptilnih ili promenljivih karakteristika u slikama.

2. Duboko učenje za analizu medicinskih slika:

Prednosti: Duboko učenje omogućava modelima da automatski nauče karakteristike i obrasce direktno iz podataka, što može poboljšati sposobnost modela da detektuje suptilne promene i složene obrasce prisutne u medicinskim slikama. Takođe, duboke neuronske mreže mogu biti vrlo efikasne u obradi velikih količina podataka.

Mane: Duboke neuronske mreže često zahtevaju velike količine označenih podataka za obuku, što može biti izazovno u medicinskim aplikacijama gde je označavanje podataka skupo ili teško. Osim toga, duboke mreže mogu biti sklonije preobučivosti ako nisu adekvatno regularizovane ili ako se koriste sa nedovoljno podataka.

3. Transformer pristupi za segmentaciju slika:

Prednosti: Transformer pristupi pokazuju sposobnost hvatanja globalnih zavisnosti i konteksta u slikama, što može biti korisno za segmentaciju medicinskih slika sa kompleksnim prostornim odnosima. Ovi pristupi mogu efikasno koristiti *self-attention* mehanizme za obradu informacija u slikama.

Mane: Transformer pristupi mogu biti računski zahtevni i zahtevati velike količine podataka za obuku, slično kao duboke neuronske mreže. Osim toga, interpretacija transformera može biti izazovna zbog njihove kompleksnosti i nerazumljivosti.

4. Opis metode

1. Skup podataka

Skup podataka koji je korišten za obuku i evaluaciju modela sastoji se od 105 *x-ray* slika dojki, uz odgovarajuće maske koje označavaju lokaciju kancerogenih masa na dojnama. U imenima svake slike nalazi se *ID* pacijenta radi lakšeg praćenja i identifikacije. Skup podataka je podjeljen na 5 podskupova: A, B, C, D, E, koji će biti korišćeni za kros-validaciju. To znači da se slike svakog pacijenta mogu naći u samo jednom od ovih 5 podskupova. Svaki od podskupova sadrži originalne *x-ray* slike i odgovarajuće maske.

2. Kros-validacija

Korištena je kros-validacija kako bi se obezbjedila pouzdana procjena performansi modela. Kros-validacija omogućava da se koriste svi dostupni podaci za obuku i testiranje modela, čime se minimizira uticaj varijabilnosti raspodele podataka. Različiti podskupovi (A, B, C, D, E) se koriste kao testni skupovi u različitim iteracijama kros-validacije, dok se preostali podaci koriste za obuku modela.

Ovakav pristup omogućava da se objektivno procijene generalizacijske sposobnosti modela i da se identifikuju eventualni problemi sa natprilagođenjem ili nedostatkom generalizacije. Takođe, omogućava da se utvrdi stabilnost performansi modela kroz različite podskupove podataka, što je ključno za pouzdanu primenu u kliničkoj praksi.

3. Opis model i proces treniranja

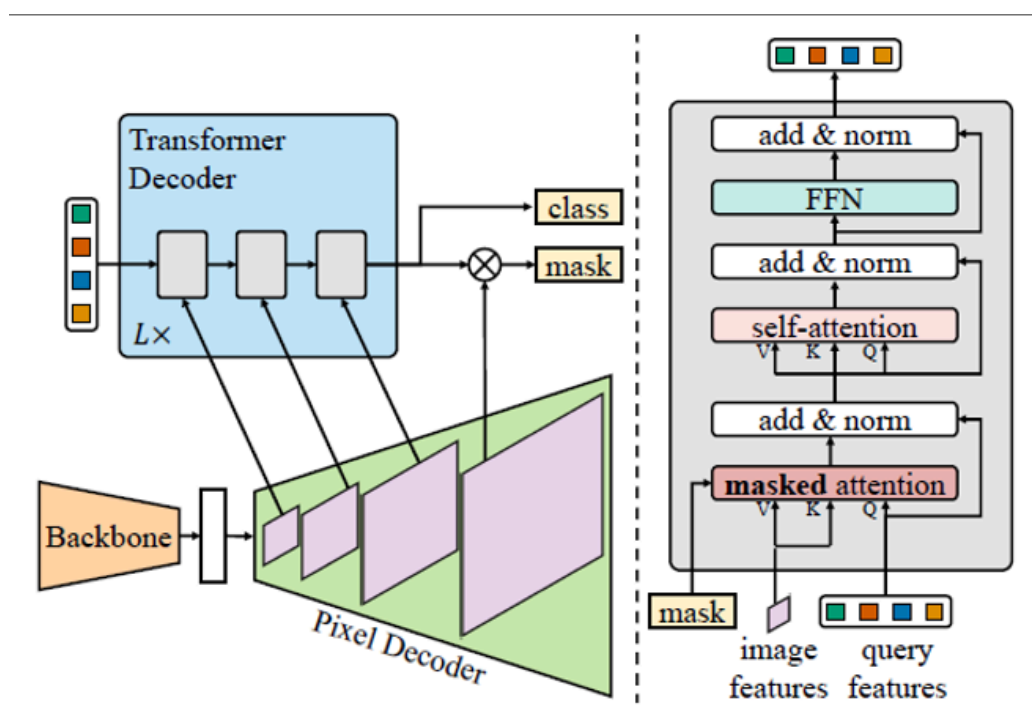
Za implementaciju rešenja, korištena je biblioteka *mmsegmentation* koja pruža jednostavno korišćenje različitih modela dubokog učenja, kao i jednostavno podešavanje parametara treninga.

Korišteni model je *Mask2Former* koje je prikazan na slici Slika 2. i on se sastoji od ResNet mreže kao osnove (*backbone*). ResNet mreža se prvo koristi za obradu slika kako bi izvukle bitne karakteristike. Zatim se koristi *Deformable Attention Module Transformer* za enkodovanje slike, što predstavlja *pixel decoder*. Nakon toga, sledi

transformer decoder koji generiše masku koja označava prepoznate oblasti na slici, kao i klasu koja predstavlja vrstu prepoznate oblasti. Postoje dvije klase: jedna označava da nije pronađena nikakva abnormalnost (*None*), dok druga označava prepoznatu kancerogenu masu (*Mass*).

Ulazne slike su podešene na veličinu 512x512 piksela pre nego što se ubace u model.

Proces treniranja sastoji se od 1000 iteracija, pri čemu se nakon svake 10. iteracije vrši validacija. Ukupno je sprovedeno 5 različitih treninga, pri čemu se u svakom trenutku 3 od 5 podskupova koristi kao trening skup, jedan kao validacioni, a jedan kao testni skup. Ovaj pristup omogućava da se adekvatno procjene performanse modela na različitim skupovima podataka i da se obezbedi pouzdanost i generalizacija modela.



Slika 2. Arhitektura modela *Mask2Former*

5. Rezultati

1. Metrike evaluacije

U procesu evaluacije performansi modela koriste se dvije ključne metrike: IoU (*Intersection over Union*) i Acc (*Accuracy*).

- IoU (*Intersection over Union*): Ova metrika mjeri stepen preklapanja između stvarne maske (*ground truth*) i predviđene maske. Računa se kao površina presjeka (*intersection*) podjeljena sa površinom unije (*union*) dve maske. IoU daje vrednost između 0 i 1, gdje vrijednost bliža 1 ukazuje na veće preklapanje između predviđene i stvarne maske, što je indikator preciznosti modela.
- Acc (*Accuracy*): Ova metrika mjeri tačnost klasifikacije predviđenih maski u odnosu na stvarne klase. Računa se kao odnos tačno klasifikovanih piksela prema ukupnom broju piksela u slici. Acc takođe daje vrednost između 0 i 1, gde vrednost bliža 1 ukazuje na veću tačnost u klasifikaciji maski.

2. Rezultati kros-validacije

U narednoj tabeli Tabela 1. su prikazani rezultati svake trening iteracije. Kolone predstavljaju koji su se podskupovi koristili kao trening skup, koji kao validacioni skup a koji kao test skup, kao i navedene metrike za svaku od klasa.

Test skup	Validacion i skup	Trening skup	IoU klasa None	Acc klasa None	IoU klasa Mass	Acc klasa Mass
A	B	C, D, E	0,98	0,99	0,0038	0,0038
B	C	D, E, A	0,98	0,99	0,27	0,28
C	D	E, A, B	0,99	0,99	0,27	0,47
D	E	A, B, C	0,98	0,99	0,28	0,51
E	A	B, C, D	0,99	0,99	0,13	0,14

Tabela 1. Rezultati kros validacije

Finalni rezultati su dobijeni tako sto su rezultati svake trening iteracije za svaku klasu sabrani i onda podjeljni sa 5, da bi se dobili prosječni rezultati. Dobijeni rezultati su prikazani u Tabela 2.

Klasa	IoU	Acc
None	0,98	0,99
Mass	0,19	0,28

Tabela 2. Prosječni rezultati

6. Diskusija i zaključak

Na osnovu rezultata korišćenog modela, može se zaključiti da je model, prema podacima iz literature i iskustvu autora, pokazao izuzetne performanse i postizao odlične rezultate uz dovoljno dug period treniranja i dovoljnu količinu podataka. Međutim, dobijeni rezultati nisu dostigli isti nivo performansi, što je delimično rezultat nedostatka podataka.

Nedostatak podataka ograničio je generalizaciju modela i sprečio postizanje optimalnih rezultata. Da postoji veći broj podataka i resursi za duže treniranje, vrlo je vjerovatno da bi rezultati bili značajno poboljšani. Ipak, čak i uz ove izazove, dobijeni model nije pokazao dovoljno visok nivo performansi koji bi ga činio korisnim za praktičnu primenu u kliničkoj praksi.

U budućnosti, fokus bi trebalo staviti na prikupljanje većeg broja kvalitetnih podataka i korišćenje naprednijih tehnika treniranja kako bi se unapredile performanse modela. Takođe, istraživanje alternativnih pristupa i tehnika za rešavanje ovog problema takođe bi moglo doprinjeti boljim rezultatima u budućnosti.

7. Reference

- *Mask2Former* naucni rad - <https://arxiv.org/pdf/2112.01527v3.pdf>
- *MaskFormer* naucni rad - <https://arxiv.org/pdf/2201.00520.pdf>
- *Deformable Attention Module* naucni rad - <https://arxiv.org/pdf/2010.04159v4.pdf>
- INBreast baza - <https://drive.google.com/file/d/1BnBNAGGO5Vcgec3NRdKLdqh7o7pNNpch/view>
- *mmsegmentation* biblioteka - <https://github.com/open-mmlab/msegmentation/tree/main>